



Tech Challenge – Fase 4:

Previsão Obesidade

Storytelling Técnico + Justificativa Técnica + Insights

Aluno 1: Luis Gustavo Barbosa Ribeiro

Aluno 2: Raimar de Assis Modesto

Curso: Pós-Tech FIAP – Data Analytics

Data da entrega: 31/05/2026

1. Introdução

A obesidade é um dos principais desafios de saúde pública da atualidade, estando associada ao aumento do risco de diversas doenças crônicas, como diabetes, hipertensão arterial, doenças cardiovasculares e problemas metabólicos. Segundo organizações de saúde nacionais e internacionais, a identificação precoce de fatores de risco relacionados ao ganho excessivo de peso é fundamental para a promoção da qualidade de vida e para a prevenção de complicações futuras.

Com o avanço das técnicas de Ciência de Dados e Machine Learning, tornou-se possível analisar grandes volumes de informações relacionadas aos hábitos de vida, características físicas e comportamentais dos indivíduos, permitindo a construção de modelos capazes de identificar padrões e realizar previsões com elevado nível de precisão.

Neste contexto, o presente projeto foi desenvolvido com o objetivo de aplicar técnicas de análise de dados, engenharia de atributos e aprendizado de máquina para construir um sistema inteligente capaz de prever o nível de obesidade de um paciente a partir de suas características e hábitos de vida. Além da construção do modelo preditivo, foi desenvolvido um dashboard analítico para geração de insights e uma aplicação web interativa utilizando Streamlit, permitindo que profissionais da área da saúde realizem análises de forma simples e intuitiva.

O projeto contempla todas as etapas de um pipeline de Machine Learning, desde o tratamento dos dados e criação de novas variáveis até o treinamento, avaliação e disponibilização do modelo em ambiente web, demonstrando na prática a aplicação dos conceitos estudados ao longo da pós-graduação.

2. Objetivo

Objetivo Geral

Desenvolver uma solução baseada em Machine Learning capaz de prever o nível de obesidade de indivíduos a partir de informações físicas, hábitos alimentares e estilo de vida, disponibilizando os resultados por meio de uma aplicação web interativa para apoio à tomada de decisão.

Objetivos Específicos

- Realizar o tratamento e preparação da base de dados disponibilizada para o desafio.
- Aplicar técnicas de Feature Engineering para aumentar o potencial preditivo do modelo.
- Construir e avaliar um modelo de Machine Learning utilizando o algoritmo Random Forest.
- Garantir desempenho superior ao requisito mínimo de 75% de assertividade definido no desafio.
- Desenvolver uma aplicação web utilizando Streamlit para disponibilizar o modelo de forma acessível aos usuários.

- Construir um painel analítico com indicadores e visualizações que permitam identificar padrões relacionados à obesidade.
- Disponibilizar todo o código-fonte em repositório GitHub para garantir rastreabilidade e reprodutibilidade do projeto.
- Demonstrar como a Ciência de Dados pode auxiliar profissionais da área médica na identificação de fatores de risco e no apoio à prevenção da obesidade.

Resultado Esperado

Ao final do projeto, espera-se disponibilizar uma solução completa composta por modelo preditivo, dashboard analítico e aplicação web, permitindo que equipes médicas obtenham previsões rápidas e visualizem informações relevantes para apoiar estratégias de prevenção e acompanhamento de pacientes com risco de obesidade.

3. Aquisição e Exploração dos Dados

A primeira etapa do projeto consistiu na aquisição e compreensão da base de dados disponibilizada para o desafio. O conjunto de dados utilizado contém informações relacionadas às características físicas, hábitos alimentares, nível de atividade física e estilo de vida dos indivíduos, além da classificação do respectivo nível de obesidade.

Após a obtenção da base, foi realizada uma análise exploratória dos dados (EDA – Exploratory Data Analysis) com o objetivo de compreender a estrutura das informações, identificar possíveis inconsistências e avaliar o comportamento das variáveis disponíveis. Nessa etapa foram analisados aspectos como:

- Quantidade de registros e variáveis presentes na base;
- Tipos de dados (numéricos e categóricos);
- Distribuição das classes de obesidade;
- Existência de valores nulos ou inconsistentes;
- Relações entre hábitos de vida e níveis de obesidade;
- Correlações entre variáveis quantitativas.

Durante a exploração inicial, observou-se que fatores como peso, altura, frequência de atividade física, histórico familiar de obesidade e hábitos alimentares apresentavam forte relação com a variável alvo. Essas análises permitiram compreender melhor o problema de negócio e serviram como base para a etapa seguinte de tratamento dos dados e engenharia de atributos.

A análise exploratória foi fundamental para direcionar as decisões adotadas ao longo do projeto, garantindo maior qualidade dos dados utilizados no treinamento do modelo preditivo e contribuindo para a obtenção de resultados mais confiáveis.

4. Pipeline de Machine Learning e Feature Engineering

Após a etapa de exploração dos dados, foi desenvolvido um pipeline completo de Machine Learning com o objetivo de transformar os dados brutos em informações estruturadas e adequadas para treinamento do modelo preditivo.

Inicialmente foi realizado o tratamento e limpeza dos dados, incluindo padronização de formatos, correção de inconsistências e adequação dos tipos de variáveis. Em seguida, foi realizada a tradução e enriquecimento das informações para tornar os dados mais compreensíveis e interpretáveis durante as análises.

A etapa de Feature Engineering teve papel fundamental no projeto, sendo responsável pela criação de novas variáveis derivadas capazes de aumentar o poder preditivo do modelo. Entre os principais atributos desenvolvidos destacam-se:

- Cálculo automático do Índice de Massa Corporal (IMC);
- Conversão de variáveis categóricas em variáveis binárias;
- Criação de scores para hábitos alimentares e comportamentais;
- Codificação das variáveis de transporte utilizando One-Hot Encoding;
- Padronização das variáveis utilizadas pelo algoritmo de Machine Learning.

Após a criação das novas variáveis, foi realizada a preparação da base para modelagem, definindo as variáveis independentes (X) e a variável alvo (y), correspondente ao nível de obesidade.

Na sequência, os dados foram divididos entre conjuntos de treinamento e teste, permitindo avaliar a capacidade de generalização do modelo. Para a etapa de treinamento foi utilizado o algoritmo Random Forest Classifier, escolhido por sua robustez, capacidade de lidar com variáveis categóricas e numéricas, além de apresentar excelente desempenho em problemas de classificação.

Por fim, o modelo foi avaliado utilizando métricas de desempenho, exportado em formato .pkl e disponibilizado em uma aplicação web desenvolvida em Streamlit, permitindo que novos pacientes sejam avaliados em tempo real por meio da interface desenvolvida pelo grupo.

A Figura 1 apresenta de forma resumida todo o fluxo de desenvolvimento da solução, desde a aquisição dos dados até a disponibilização do sistema preditivo para apoio à tomada de decisão médica.




Figura 1 – Pipeline completo de Machine Learning utilizado no desenvolvimento do Sistema Preditivo de Obesidade.


5. Avaliação e Assertividade do Modelo

Após a conclusão do treinamento, o modelo foi submetido a um processo de validação utilizando dados que não participaram do treinamento, permitindo avaliar sua capacidade de generalização em cenários reais.

O algoritmo Random Forest apresentou desempenho superior ao requisito mínimo estabelecido pelo desafio (75% de assertividade), alcançando um elevado nível de precisão na classificação dos diferentes níveis de obesidade presentes na base de dados.

Para validação dos resultados foram utilizadas métricas clássicas de classificação, incluindo acurácia, matriz de confusão e relatório de classificação (Classification Report). Essas métricas permitiram analisar não apenas a taxa geral de acertos, mas também a capacidade do modelo em distinguir corretamente cada categoria de obesidade.

Os resultados obtidos demonstram que o modelo foi capaz de identificar padrões relevantes nos dados relacionados aos hábitos de vida, características físicas e fatores comportamentais dos indivíduos, tornando-se uma ferramenta confiável para apoio à análise e tomada de decisão.



A Figura 2 apresenta a acurácia obtida durante a etapa de validação do modelo.

6. Deploy da Aplicação Preditiva em Streamlit

Após o treinamento e avaliação do modelo, realizamos a etapa de deploy da solução utilizando o Streamlit, uma ferramenta que permite transformar códigos Python em aplicações web interativas de forma simples e acessível.

O objetivo dessa etapa foi disponibilizar o modelo preditivo em uma interface amigável, permitindo que usuários da área da saúde preencham as informações de um paciente e recebam, em tempo real, a previsão do nível de obesidade.

Para viabilizar o deploy, exportamos os principais artefatos do modelo em arquivos `.pkl`, sendo eles:

- **modelo_obesidade.pkl**: modelo Random Forest treinado;
- **encoder_obesidade.pkl**: responsável por traduzir a saída numérica do modelo para o nível de obesidade correspondente;
- **features_modelo.pkl**: lista de variáveis utilizadas no treinamento, garantindo que a aplicação utilize os mesmos campos na mesma ordem.

Em seguida, desenvolvemos o arquivo **app.py**, responsável por estruturar a aplicação Streamlit. Nele foram implementadas as telas de entrada de dados do paciente, o cálculo automático do IMC, a conversão das respostas para o padrão utilizado pelo modelo e a execução da predição.

A aplicação foi organizada com duas visões principais:

- **Sistema Preditivo**: permite preencher os dados do paciente e obter a previsão do nível de obesidade;
- **Dashboard Analítico**: apresenta indicadores e gráficos com os principais insights encontrados na base de dados.

Todo o projeto foi versionado em um repositório público no GitHub, contendo o código da aplicação, os arquivos do modelo, a base de dados e o arquivo **requirements.txt** com as bibliotecas necessárias para execução.

Por fim, a aplicação foi publicada no Streamlit Community Cloud, permitindo o acesso por meio de um link público. Dessa forma, o modelo deixou de ser apenas um experimento em notebook e passou a funcionar como uma solução prática de apoio à decisão médica.

<https://tech-challenge-obesidade-bokz6t4snjup8equajudtx.streamlit.app/>

The screenshot shows a Streamlit web application titled "Aplicação para auxiliar equipes médicas na previsão do nível de obesidade." The interface is divided into three main sections: "Dados do Paciente", "Hábitos de Saúde", and "Resumo do Paciente".

Dados do Paciente: This section contains nine dropdown menus for patient data. The first row includes "Gênero" (Feminino), "Peso (kg)" (80,00), and "Fuma?" (Não). The second row includes "Idade" (30), "Histórico familiar de excesso de peso?" (Não), and "Monitora calorias diariamente?" (Não). The third row includes "Altura (m)" (1,70), "Consome alimentos calóricos com frequência?" (Não), and "Meio de transporte habitual" (Transporte Público).

Hábitos de Saúde: This section contains six dropdown menus for health habits. The first row includes "Consumo de vegetais" (Raramente), "Consumo de água diário" (Menos de 1 litro), and "Tempo em dispositivos eletrônicos" (0 a 2 horas). The second row includes "Refeições principais por dia" (Uma refeição), "Frequência de atividade física" (Nenhuma), and "Come entre as refeições?" (Não). The third row includes "Consumo de álcool" (Não).

Resumo do Paciente: This section displays the calculated BMI: "IMC calculado: 27.68". Below this is a button labeled "Realizar Predição". The prediction result is shown in a green box: "Nível previsto: Sobrepeso Grau II". At the bottom, a blue box contains a disclaimer: "Este sistema é um apoio à decisão e não substitui a avaliação clínica realizada por profissionais de saúde."

On the left side, there is a "Menu" sidebar with two options: "Sistema Preditivo" (selected) and "Dashboard Analítico". In the top right corner, there are icons for "Share", "Star", "Refresh", and "Help". In the bottom right corner, there is a "Manage app" button.

Figura 3 – Interface da aplicação preditiva desenvolvida em Streamlit para classificação do nível de obesidade de pacientes.

7. Construção do Dashboard Analítico

Além do modelo preditivo, foi desenvolvida uma visão analítica com o objetivo de transformar os dados em informações estratégicas para apoiar profissionais da área da saúde na compreensão dos fatores relacionados à obesidade.

Inicialmente, avaliamos a possibilidade de desenvolver o painel analítico utilizando o Power BI, ferramenta amplamente utilizada para visualização e análise de dados. Entretanto, considerando a necessidade de disponibilização pública da solução e a integração direta com a aplicação preditiva, optamos por centralizar toda a experiência no ambiente Streamlit.

Essa abordagem permitiu concentrar, em uma única plataforma, tanto o sistema de previsão quanto os principais indicadores analíticos, proporcionando uma experiência mais simples para o usuário final e eliminando a necessidade de acessar ferramentas distintas para consulta das informações.

O dashboard foi desenvolvido com foco em gerar insights relevantes para equipes médicas, apresentando indicadores e visualizações que permitem identificar padrões relacionados aos hábitos de vida, características físicas e níveis de obesidade dos pacientes.

Entre os principais indicadores disponibilizados estão:

- Distribuição dos níveis de obesidade na base analisada;
- Relação entre Índice de Massa Corporal (IMC) e classificação de obesidade;
- Influência da frequência de atividade física nos níveis de obesidade;
- Impacto dos hábitos alimentares na classificação dos pacientes;
- Indicadores gerais da base, como quantidade de registros e distribuição das categorias.

Os gráficos e indicadores foram projetados para facilitar a interpretação dos dados, permitindo identificar rapidamente padrões de comportamento, fatores de risco e possíveis oportunidades de atuação preventiva.

Dessa forma, o dashboard complementa o sistema preditivo, transformando os dados em conhecimento útil para apoiar análises clínicas, ações preventivas e estratégias de promoção da saúde.




Figura 4 – Dashboard analítico desenvolvido em Streamlit contendo indicadores e visualizações sobre os principais fatores associados à obesidade, auxiliando equipes médicas na identificação de padrões e fatores de risco.

8. Repositório GitHub

Com o objetivo de garantir a rastreabilidade, transparência e reprodutibilidade do projeto, todo o código-fonte desenvolvido foi disponibilizado em um repositório público no GitHub.

O repositório contém todos os artefatos utilizados durante o desenvolvimento da solução, incluindo os notebooks de análise, tratamento dos dados, treinamento do modelo, arquivos exportados do Machine Learning, código da aplicação Streamlit e demais recursos necessários para execução do projeto.

Link do repositório:

<https://github.com/luisgusbr/tech-challenge-obesidade>

9. Conclusão

O presente projeto teve como objetivo desenvolver uma solução baseada em Ciência de Dados e Machine Learning para auxiliar na previsão dos níveis de obesidade, contribuindo para o apoio à tomada de decisão de profissionais da área da saúde.

Ao longo do desenvolvimento, foram executadas todas as etapas de um pipeline completo de Machine Learning, incluindo aquisição dos dados, análise exploratória, tratamento das informações,

engenharia de atributos, treinamento do modelo, avaliação de desempenho e disponibilização da solução em ambiente web.

Os resultados obtidos demonstraram a capacidade do modelo em identificar padrões relevantes relacionados aos hábitos de vida, características físicas e fatores comportamentais dos indivíduos, alcançando desempenho superior ao requisito mínimo estabelecido pelo desafio.

Além do modelo preditivo, foi desenvolvido um dashboard analítico integrado à aplicação, permitindo transformar dados em informações estratégicas para apoiar análises e identificar fatores associados à obesidade. Dessa forma, a solução não apenas prevê resultados, mas também contribui para a compreensão dos comportamentos que influenciam o desenvolvimento da condição.

Como resultado final, foi entregue uma solução completa composta por modelo preditivo, aplicação web interativa, painel analítico e repositório de código-fonte, demonstrando na prática a aplicação dos conceitos de Ciência de Dados, Machine Learning e Visualização de Dados na resolução de um problema real da área da saúde.

Por fim, o projeto evidenciou como o uso de técnicas analíticas e modelos inteligentes pode contribuir para a identificação precoce de fatores de risco, auxiliando profissionais de saúde na adoção de ações preventivas e estratégias voltadas à melhoria da qualidade de vida da população.